

Tarefa 3.5 - Análise Exploratória e Estatística Descritiva - Visualização Gráfica

Esta tarefa consiste em explorar por meio de métodos de descrição gráfica (visualização de dados) o conjunto de dados *Hourly Wages*. Você deve implementar em Python e responder os itens solicitados abaixo utilizando a biblioteca [Matplotlib](#) e/ou [Seaborn](#) e outras que desejar ou forem necessárias.

Exemplos dos gráficos solicitados estão nos links das bibliotecas acima e também no notebook [Visualização gráfica.ipynb](#).

Conjunto de dados *Hourly Wages*

Esse conjunto de dados é popularmente empregado para a tarefa de regressão em Machine Learning. Constrói-se e ajusta-se um modelo de aprendizado de máquina para prever/estimar o salário de um funcionário em função de suas características (anos de estudos, experiência de trabalho, filiação sindical, região, ocupação e sexo).

- Número de Instâncias: 534
- Número de Atributos: 9 atributos numéricos e o target (*wage_per_hour*)
- Informações dos Atributos:
 - union (filiação sindical)
 - education_yrs (anos de instrução)
 - experience_yrs (anos de experiência)
 - age (idade)
 - female (sexo)
 - marr (estado civil - casado)
 - south (região)
 - manufacturing (indústria)
 - construction (construção)
- Variável de destino (target): *wage_per_hour*

✓ Implementar os itens abaixo:

- ✓ a-) Clonar o repositório de dados da disciplina (DSBD) hospedado no GitHub.

Obs: Você pode ignorar este item caso realize a tarefa no Jupyter Notebook. O conjunto de dados Hourly Wages pode ser baixado [clicando aqui](#).

```
#importando dataset do github
!wget https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Hourly_wages/hourly_wages.csv

--2026-04-07 09:01:38-- https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Hourly_wages/hourly_wages.
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.133, 185.199.110.
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 13436 (13K) [text/plain]
Saving to: 'hourly_wages.csv.2'

hourly_wages.csv.2 100%[=====] 13.12K --.-KB/s in 0s

2026-04-07 09:01:38 (129 MB/s) - 'hourly_wages.csv.2' saved [13436/13436]
```

```
#importando bibliotecas e dependências do projeto
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
```

```
#utilizando o canvas para ler o dataset
dataset = pd.read_csv("hourly_wages.csv")
```

- ✓ b-) Ler o dataset "*Hourly_wages/hourly_wages.csv*" como dataframe utilizando a biblioteca Pandas e mostrar as 5 primeiras e 5 últimas linhas.

```
#comando .head() sem parâmetro pra mostrar as 5 primeiras linhas
dataset.head()
```

	wage_per_hour	union	education_yrs	experience_yrs	age	female	marr	south	manufacturing	construction
0	5.10	0	8	21	35	1	1	0	1	0
1	4.95	0	9	42	57	1	1	0	1	0
2	6.67	0	12	1	19	0	0	0	1	0
3	4.00	0	12	4	22	0	0	0	0	0
4	7.50	0	12	17	35	0	1	0	0	0

Próximas etapas:

[Gerar código com dataset](#)
[New interactive sheet](#)

```
#mostrando as ultimas 5 linhas
dataset.tail()
```

	wage_per_hour	union	education_yrs	experience_yrs	age	female	marr	south	manufacturing	construction
529	11.36	0	18	5	29	0	0	0	0	0
530	6.10	0	12	33	51	1	1	0	0	0
531	23.25	1	17	25	48	1	1	0	0	0
532	19.88	1	12	13	31	0	1	1	0	0
533	15.38	0	16	33	55	0	1	0	1	0

- ✓ c-) Mostrar os histogramas dos atributos: *education_yrs*, *experience_yrs* e *age* num mesmo quadro de plotagem (usando *subplots*).

```
#declarando e atribuindo cada variável a uma coluna
x = dataset['education_yrs']
y = dataset['experience_yrs']
z = dataset['age']
```

```
#plotando o histograma de coluna 'education_years'
```


```
plt.subplot(1, 3, 1) #1 linha 3 colunas e grafico na pose 1
plt.hist(x, bins=10, color='skyblue', edgecolor='black')
plt.title('Anos de Educação')
plt.xlabel('Anos')
plt.ylabel('Frequência')
```

```
#hist para experience_yrs
plt.subplot(1, 3, 2) # 1 linha, 3 colunas, gráfico na posição 2
plt.hist(y, bins=10, color='lightgreen', edgecolor='black')
plt.title('Anos de Experiência')
plt.xlabel('Anos')
```

```
#age
plt.subplot(1, 3, 3) # 1 linha, 3 colunas, gráfico na posição 3
plt.hist(z, bins=10, color='salmon', edgecolor='black')
plt.title('Idade')
plt.xlabel('Idade')
```

```
#ajusta layout
plt.tight_layout()
```

```
#exibe graficos
plt.show()
```



- ✓ d-) Mostrar os gráficos de setores (*pie chart*) de cada um dos atributos: *union*, *female*, *marr*, *south*, *manufacturing* e *construction* num mesmo quadro de plotagem (usando subplots).

```
#organizamos desses dados em uma lista
atributos = ['union', 'female', 'marr', 'south', 'manufacturing', 'construction']

#quadro q ira incluir as imagens
plt.figure(figsize=(60, 20))

#usando for p criar os subplots
for i, coluna in enumerate(atributos):
    #posicao
    plt.subplot(2, 3, i + 1)


    #contagem de cara atributo
    contagem = dataset[coluna].value_counts()

    #grafico pizza
    plt.pie(contagem, labels=contagem.index, autopct='%1.1f%%', startangle=140,
            colors=['lightskyblue', 'lightcoral'])

    #titulo
    plt.title(f'Gráfico de Setores: {coluna}', fontsize=30)

#espaçamento p nao quebrar titulos
plt.tight_layout()

#mostra resultado
plt.show()
```



- ▼ e-) Mostrar os boxplots das variáveis *education_yrs*, *experience_yrs* e *age* num mesmo quadro de plotagem (usando *subplots*).

```
#parametro p tamanho da fig, mesmo do padrao anterior
plt.figure(figsize=(80, 20))


#boxplot d education years
plt.subplot(1, 3, 1)
plt.boxplot(x, patch_artist=True, boxprops=dict(facecolor='skyblue'))
plt.title('Boxplot: Anos de Educação', fontsize=40)
plt.ylabel('Anos')

# experience_yrs
plt.subplot(1, 3, 2) #1 linha, 3 colunas, posição 2
plt.boxplot(y, patch_artist=True, boxprops=dict(facecolor='lightgreen'))
plt.title('Boxplot: Anos de Experiência', fontsize=40)
plt.ylabel('Anos')

#age
plt.subplot(1, 3, 3) # 1 linha, 3 colunas, posição 3
plt.boxplot(z, patch_artist=True, boxprops=dict(facecolor='salmon'))
plt.title('Boxplot: Idade', fontsize=40)
plt.ylabel('Idade')

#ajustando layout pra nao quebrar titulos
plt.tight_layout()

plt.show()
```



- ▼ f-) Mostre lado a lado os boxplots da variável *age* discriminados por sexo (female).

```
idade_homens = dataset[dataset['female'] == 0]['age']
idade_mulheres = dataset[dataset['female'] == 1]['age']
```

```
plt.figure(figsize=(8, 6))

#boxplot p os dois gêneros
caixas = plt.boxplot([idade_homens, idade_mulheres],
                    labels=['Homens (0)', 'Mulheres (1)'], #labels serve como parametro p saber se é homem ou m
                    patch_artist=True)


#colorir c diferentes cores
cores = ['lightblue', 'lightpink']
for caixa, cor in zip(caixas['boxes'], cores):
    caixa.set_facecolor(cor)

#titulos e textos informativos
plt.title('Distribuição de Idade por Sexo', fontsize=16)
plt.ylabel('Idade (Anos)', fontsize=14)
plt.xlabel('Sexo', fontsize=14)

#numeros
plt.tick_params(axis='both', labelsize=12)

plt.show()
```

/tmp/ipykernel_4492/1521186867.py:7: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been r
caixas = plt.boxplot([idade_homens, idade_mulheres],



✓ g-) Responda observando os boxplots construídos no item anterior:

i-) Qual sexo apresenta maior variabilidade (dispersão) de idade? Resposta: A hipótese inicial é de que sejam as mulheres, tendo em vista que o percentil 0 de ambos os histogramas está próximo, porém o percentil 100, ou seja, aqueles que atingiram a maior idade por sexo, apresenta divergência.

ii-) Qual é aproximadamente o 2o. quartil das idades das mulheres? Resposta: Podemos afirmar, após análise visual, que o segundo quartil está próximo de 35

iii-) Qual é aproximadamente o 1o. quartil das idades dos homens? Resposta: Próximo a 27 anos

GERANDO DEMONSTRAÇÕES MATEMÁTICAS

```
print("i-) Dispersão e Extremos de Idade por Sexo")

#desvio padrao (std), variancia(var), minimo(percentil 0) e maximo(percentil 100)
dispersao_idade = dataset.groupby('female')['age'].agg(
    Desvio_Padrao='std',
    Variancia='var',
    Minimo_Perc0='min',
    Maximo_Perc100='max'
)
print(dispersao_idade)
print("\n" + "="*50 + "\n")
```

```
print("ii-) e iii-) Quartis de Idade por Sexo ---")

#0.25 = 1º quart 0.50 = 2º quartil 0.75 = 3º quartil
quartis_idade = dataset.groupby('female')['age'].quantile([0.25, 0.50, 0.75]).unstack()

#renomeando colunas
quartis_idade.columns = ['1º Quartil (25%)', '2º Quartil (50%)', '3º Quartil (75%)']
print(quartis_idade)
```

```
i-) Dispersão e Extremos de Idade por Sexo
Desvio_Padiao  Variancia  Minimo_Perc0  Maximo_Perc100
female
0      11.441256  130.902345      18      64
1      11.999794  143.995049      18      64

=====

ii-) e iii-) Quartis de Idade por Sexo ---
1º Quartil (25%)  2º Quartil (50%)  3º Quartil (75%)
female
0      27.0      34.0      42.0
1      28.0      35.0      46.0
```

- h-) Mostre lado a lado os boxplots da variável *wage_per_hour* discriminados por sexo (female).

```
#salarios c discriminacao de parametros hora e sexo
salario_homens = dataset[dataset['female'] == 0]['wage_per_hour']
salario_mulheres = dataset[dataset['female'] == 1]['wage_per_hour']

plt.figure(figsize=(8, 6))

#boxplot c 2 dois gps lado a lado
caixas = plt.boxplot([salario_homens, salario_mulheres],
                      labels=['Homens (0)', 'Mulheres (1)'],
                      patch_artist=True)

#colore caixas
cores = ['lightblue', 'lightpink']
for caixa, cor in zip(caixas['boxes'], cores):
    caixa.set_facecolor(cor)

#add titulos
plt.title('Distribuição do Salário por Hora por Sexo', fontsize=16)
plt.ylabel('Salário por Hora', fontsize=14)
plt.xlabel('Sexo', fontsize=14)

#tamanho de numeros e textos
plt.tick_params(axis='both', labelsize=12)

plt.show()
```

```
/tmp/ipykernel_4492/3137771430.py:8: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been r
caixas = plt.boxplot([salario_homens, salario_mulheres],
```

Distribuição do Salário por Hora por Sexo

i-) Análise comparativamente os boxplots do item anterior e comente as informações que podem ser exploradas a respeito dos salários por hora de homens e mulheres. Quais conclusões podemos obter?

Resposta: A interpretação visual dos dados nos permite perceber que, em geral, a média salarial feminina é menor, tendo em vista que elas possuem uma amplitude menor. Ambos estão em níveis diferentes de medianas, também.

✓ j-) Mostre lado a lado os boxplots da variável wage_per_hour discriminados por estado civil (marr).

```
#filtrando salarios por hrs e estado civil

#dado que 0 = solteiro e 1= casado
salario_nao_casados = dataset[dataset['marr'] == 0]['wage_per_hour']
salario_casados = dataset[dataset['marr'] == 1]['wage_per_hour']

#ajusta tamanho da figura
plt.figure(figsize=(8, 6))

#boxplot c dois grupos lado a lado
caixas = plt.boxplot([salario_nao_casados, salario_casados],
                      labels=['Soltelros (0)', 'Casados (1)'],
                      patch_artist=True)

#cores
cores = ['lightcyan', 'plum']
for caixa, cor in zip(caixas['boxes'], cores):
    caixa.set_facecolor(cor)

#informacoes gerais
plt.title('Distribuição do Salário por Hora por Estado Civil', fontsize=16)
plt.ylabel('Salário por Hora', fontsize=14)
plt.xlabel('Estado Civil', fontsize=14)

#padrao de tam de numeros
plt.tick_params(axis='both', labelsize=12)

plt.show()
```

```
/tmp/ipykernel_4492/3146218173.py:11: MatplotlibDeprecationWarning: The 'labels' parameter of boxplot() has been
caixas = plt.boxplot([salario_nao_casados, salario_casados],
```

