
Tarefa 3.6 - Análise Exploratória e Estatística Descritiva - Correlação

Esta tarefa consiste em realizar a análise de correlação de variáveis (atributos) por meio de diagramas de dispersão (scatterplot) e coeficiente de correlação de Pearson utilizando as bibliotecas e funções da linguagem Python.

Você deve implementar em Python e responder os itens solicitados abaixo utilizando a biblioteca [Matplotlib](#) e/ou [Seaborn](#) e outras que desejar ou forem necessárias.

[Clique aqui](#) para acessar um exemplo de notebook que contém as funções necessárias para a realização desta tarefa.

✓ PARTE I: *dataset* [Advertising](#)

Este dataset mostra uma série de valores investidos em anúncios de TV, Rádio e jornais e os respectivos resultados de venda.

- ✓ a-) Ler o dataset "*Advertising/Advertising.csv*" como dataframe utilizando a biblioteca Pandas e mostrar as 5 primeiras e 5 últimas linhas.

```
#importando as bibliotecas e dependencias
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sea
import numpy as numpy
```

```
#carregando o diretório e importando os dados
url = 'https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/A'
```

```
#lendo o dataset direto da url porque o comando linux quebrou
dataset = pd.read_csv(url)
```

Clique duas vezes (ou pressione "Enter") para editar

```
#mostrando as informações do topo, fim e informações gerais do dataset
print(dataset.head())
print("\n")
print(dataset.tail())
print("\n")
```

```
print(dataset.info())
print("\n")
```

```

      Unnamed: 0      TV  radio  newspaper  sales
0              1  230.1   37.8         69.2   22.1
1              2   44.5   39.3         45.1   10.4
2              3   17.2   45.9         69.3    9.3
3              4  151.5   41.3         58.5   18.5
4              5  180.8   10.8         58.4   12.9

```

```

      Unnamed: 0      TV  radio  newspaper  sales
195            196   38.2    3.7         13.8    7.6
196            197   94.2    4.9          8.1    9.7
197            198  177.0    9.3          6.4   12.8
198            199  283.6   42.0         66.2   25.5
199            200  232.1    8.6          8.7   13.4

```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Unnamed: 0  200 non-null    int64
1   TV          200 non-null    float64
2   radio       200 non-null    float64
3   newspaper   200 non-null    float64
4   sales       200 non-null    float64
dtypes: float64(4), int64(1)
memory usage: 7.9 KB
None

```

Clique duas vezes (ou pressione "Enter") para editar

b-) Mostre num mesmo quadro (usando subplots) os três diagramas de dispersão para os pares de variáveis: TV x sales, radio x sales e newspaper x sales.

c-) Calcule o coeficiente de correlação de Pearson para os três pares de variáveis: TV x sales, radio x sales e newspaper x sales.

```

#criando variáveis
tv = dataset['TV']
radio = dataset['radio']
newspaper = dataset['newspaper']
sales = dataset['sales']


```


```

#plotando o gráfico com as variveis, analisando cada variável
matplotlib.scatter(sales, tv)

```

```
matplotlib.show()  
#analisar o comportamento e distribuição de cada variável da um panora  
matplotlib.scatter(sales, radio)  
matplotlib.show()  
matplotlib.scatter(sales, newspaper)  
matplotlib.show()
```





```
#obtendo cada um dos coeficientes de pearson
t = numpy.polyfit(tv, sales, 1)
r = numpy.polyfit(radio, sales, 1)
n = numpy.polyfit(newspaper, sales, 1)
```

```
[0.04753664 7.03259355]
```

```
#criando as retas de regressão para todas as variáveis
#descrevendo o comportamento por meio de funções polinomiais de grau 1
tv_function = numpy.poly1d(t)
radio_function = numpy.poly1d(r)
newspaper_function = numpy.poly1d(n)
```

```
#PLATANDO O GRÁFICO LINEAR DE CADA VARIÁVEL
```

```
#vermelho == vendas
```

```
matplotlib.plot(tv, tv_function(tv), color='red')
matplotlib.scatter(tv, sales)
matplotlib.title('Reta de Regressão: Tv X Vendas')
matplotlib.xlabel('Investimento em Televisonamento (t)')
matplotlib.ylabel('Vendas (sales)')
matplotlib.show()
```


```
##verde == radio
```



```
matplotlib.plot(radio, radio_function(radio), color='green')
matplotlib.scatter(radio, sales)
matplotlib.title('Reta de Regressão: Radio X Vendas')
matplotlib.xlabel('Investimento em Radio (r)')
matplotlib.ylabel('Vendas (sales)')
matplotlib.show()
```

```
##azul == newspaper
```

```
matplotlib.plot(newspaper, newspaper_function(newspaper), color='blue')
matplotlib.scatter(newspaper, sales)
matplotlib.title('Reta de Regressão: Newspaper X Vendas')
matplotlib.xlabel('Investimento em Newspaper (n)')
matplotlib.ylabel('Vendas (sales)')
matplotlib.show()
```








```
#dados_tips = pd.read_csv(url_tips)
url_gorjetas = 'https://raw.githubusercontent.com/mwaskom/seaborn-data'
```

```
#lendo o dataset direto da url porque o comando linux quebrou
df_gorjetas = pd.read_csv(url_gorjetas)
```

```
#mostrando as informações do topo, fim e informações gerais do dataset
print(df_gorjetas.head())
print("\n")
print(df_gorjetas.tail())
print("\n")
print(df_gorjetas.info())
print("\n")
```


	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3




```
#criando variáveis
conta = df_gorjetas['total_bill']
gorjeta_valor = df_gorjetas['tip']
tamanho_mesa = df_gorjetas['size']
dia_semana = df_gorjetas['day']
```

f-) Mostre o diagrama de dispersão entre as variáveis "total_bill" e "tip" com a reta de regressão utilizando a função *polyfit* da biblioteca numpy.

```
#plotando o gráfico com as variveis, analisando cada variável
matplotlib.scatter(gorjeta_valor, conta)
matplotlib.show()
#analisar o comportamento e distribuição de cada variável da um panoram
matplotlib.scatter(gorjeta_valor, tamanho_mesa)
matplotlib.show()
matplotlib.scatter(gorjeta_valor, dia_semana)
matplotlib.show()
```



- g-) Utilizando os coeficientes a e b da reta de regressão, calcule qual será a gorjeta (tip) estimada para uma conta total (total_bill) igual a um valor fornecido pelos usuário.

```
#obtendo cada um dos coeficientes da reta de regressao
c = numpy.polyfit(conta, gorjeta_valor, 1)
tm = numpy.polyfit(tamanho_mesa, gorjeta_valor, 1)



# Nota: A variável 'dia_semana' foi excluída deste cálculo por ser cati
# Modelos matemáticos puros como o polyfit requerem variáveis numérica
```

```
#criando as retas de regressão para todas as variáveis
#descrevendo o comportamento por meio de funções polinomiais de grau 1
conta_function = numpy.poly1d(c)
tamanhomesa_function = numpy.poly1d(tm)

#PLATANDO O GRÁFICO LINEAR DE CADA VARIÁVEL
#vermelho == gorjetas
matplotlib.pyplot.plot(conta, conta_function(conta), color='red')
matplotlib.pyplot.scatter(conta, gorjeta_valor)
matplotlib.pyplot.title('Reta de Regressão: Conta X Gorjeta')
matplotlib.pyplot.xlabel('Valor da Conta (c)')
matplotlib.pyplot.ylabel('Gorjeta (gorjeta_valor)')
matplotlib.pyplot.show()

##verde == tamanho da mesa
matplotlib.pyplot.plot(tamanho_mesa, tamanhomesa_function(tamanho_mesa), color='v')
matplotlib.pyplot.scatter(tamanho_mesa, gorjeta_valor)
matplotlib.pyplot.title('Reta de Regressão: Tamanho da Mesa X Gorjeta')
matplotlib.pyplot.xlabel('Tamanho da Mesa (tm)')
matplotlib.pyplot.ylabel('Gorjeta (gorjeta_valor)')
matplotlib.pyplot.show()
```





h-) Faça o mesmo para estimar o valor total da conta (total_bill) para um valor de gorjeta (tip) fornecido pelo usuário?

```
#criando a reta de regressão para prever a conta usando a gorjeta
#descrevendo o comportamento por meio de funções polinomiais de grau 1
#atenção: invertemos a ordem no polyfit para X=gorjeta_valor e Y=conta
ci = numpy.polyfit(gorjeta_valor, conta, 1)

#criando a função polinomial
contaprevista_function = numpy.polyld(ci)

#solicitando o valor de gorjeta ao usuário (tip)
valor_informado = float(input('Forneça um valor de gorjeta para estima

#calculando a estimativa
conta_estimada = contaprevista_function(valor_informado)

#exibindo o resultado
print(f'Para uma gorjeta de ${valor_informado:.2f}, a estimativa do va
```

- ✓ i-) Calcule o coeficiente de correlação de Pearson para total_bill e tip.

```
#calculando o coeficiente de correlação de Pearson para total_bill e t

#atalho direto do Pandas (mais limpo para DataFrames)
pearson_pandas = conta.corr(gorjeta_valor)

#o numpy (retorna uma matriz, então pegamos o valor da linha 0 e coluna 1)
matriz_correlacao = numpy.corrcoef(conta, gorjeta_valor)
pearson_numpy = matriz_correlacao[0, 1]

#exibindo o resultado (ambos darão exatamente o mesmo valor)
print(f'0 coeficiente de correlação de Pearson é: {pearson_pandas:.4f}
```

0 coeficiente de correlação de Pearson é: 0.6757

- ✓ j-) Responda:

i-) Existe correlação entre 'total_bill' e 'tip'? Resp:

ii-) Se sim, a correlação é positiva ou negativa? Resp:

iii-) Se sim, qual o grau de correlação? Forte, moderada ou fraca? Resp:

j-) Responda: i-) Existe correlação entre 'total_bill' e 'tip'? Resp: Sim.

ii-) Se sim, a correlação é positiva ou negativa? Resp: Positiva (o coeficiente é maior que zero, o que significa que conforme o valor da conta aumenta, o valor da gorjeta também tende a aumentar).

iii-) Se sim, qual o grau de correlação? Forte, moderada ou fraca? Resp: Moderada (na estatística, convencionou-se que valores entre 0.3 e 0.7 representam uma correlação moderada. Como o valor é de ~0.675, é uma correlação moderada, porém muito próxima de ser considerada forte).

✓ PARTE III: *dataset* [Atlas Brasil](#)

Este dataset mostra diferentes atributos valores de variáveis sociais para cada um dos estados brasileiros:

- ANOEST = Média de anos de estudo
- T_ANALF25M = Taxa de analfabetismo - 25 anos ou mais
- MORT1 = Mortalidade infantil
- RDPC = Renda per capita
- POPTOT = População total
- IDHM = IDHM

```
import seaborn as sns

#carregando o diretório e importando os dados
url_atlas = 'https://raw.githubusercontent.com/malegopc/DSBD/main/Data

#lendo o dataset direto da url porque o comando linux quebrou
df_atlas = pd.read_csv(url_atlas)

#mostrando as informações do topo, fim e informações gerais do dataset
print(df_atlas.head())
print("\n")
print(df_atlas.tail())
print("\n")
print(df_atlas.info())
print("\n")
```

	ESTADO	MORT1	ANOEST	T_ANALF25M	RDPC	POPT	IDHM
0	RO	20.82	8.31	10.66	667.41	1641072	0.715
1	AC	18.37	7.95	17.19	548.24	762502	0.719
2	AM	19.38	9.21	8.06	579.45	3769444	0.709
3	RR	17.57	9.29	9.95	665.19	472758	0.732
4	PA	17.65	7.78	12.81	469.47	7615746	0.675

	ESTADO	MORT1	ANOEST	T_ANALF25M	RDPC	POPT	IDHM
22	RS	10.16	8.97	5.30	1000.62	10851074	0.779
23	MS	14.94	8.80	7.77	930.50	2599715	0.762

24	MT	17.71	8.74	9.09	844.21	3141541	0.767
25	G0	15.79	8.60	9.59	796.18	6373595	0.750
26	DF	10.99	10.98	3.35	1606.40	2756412	0.839

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27 entries, 0 to 26
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   ESTADO      27 non-null     object
1   MORT1        27 non-null     float64
2   ANOSEST      27 non-null     float64
3   T_ANALF25M  27 non-null     float64
4   RDPC         27 non-null     float64
5   POPT         27 non-null     int64
6   IDHM         27 non-null     float64
dtypes: float64(5), int64(1), object(1)
memory usage: 1.6+ KB
None
```

✓ k-) Ler o dataset "*Atlas/Atlas_Brasil_2014.csv*" como dataframe utilizando a biblioteca Pandas

```
#carregando o diretório e importando os dados
url_atlas = 'https://raw.githubusercontent.com/malegopc/DSBD/main/Data

#lendo o dataset direto da url porque o comando linux quebrou
df_atlas = pd.read_csv(url_atlas)
```

✓ l-) Utilizando a função "[pairplot](#)" da biblioteca seaborn mostre os diagramas de dispersão com suas respectivas retas de regressão entre todos os pares de variáveis.

```
#o parâmetro kind='reg' é o responsável por desenhar as retas de regressão
sns.pairplot(df_atlas, kind='reg')

#mostrando o gráfico gerado
matplotlib.pyplot.show()
```