

Tarefa 3.4 - Análise Exploratória e Estatística Descritiva - Medidas estatísticas utilizando Python

Esta tarefa consiste analisar por meio de métodos de descrição paramétrica (medidas estatísticas) o conjunto de dados *Hourly Wages*. Você deve implementar em Python os itens solicitados abaixo utilizando a biblioteca Pandas e outras que forem necessárias.

Conjunto de dados *Hourly Wages*

Esse conjunto de dados é popularmente empregado para a tarefa de regressão em Machine Learning. Constrói-se e ajusta-se um modelo de aprendizado de máquina para prever/estimar o salário de um funcionário em função de suas características (anos de estudos, experiência de trabalho, filiação sindical, região, ocupação e sexo).

- Número de Instâncias: 534
- Número de Atributos: 9 atributos numéricos e o target (*wage_per_hour*)
- Informações dos Atributos:
 - union (filiação sindical)
 - education_yrs (anos de instrução)
 - experience_yrs (anos de experiência)
 - age (idade)
 - female (sexo)
 - marr (estado civil - casado)
 - south (região)
 - manufacturing (indústria)
 - construction (construção)
- Variável de destino (target): *wage_per_hour*

✓ Implementar os itens abaixo:

- ✓ a-) Clonar o repositório de dados da disciplina (DSBD) hospedado no GitHub.

```
#bash no linux para baixar o dataset na pasta, a tentativa de clonagem apresentou quebras
!wget https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Hourly_wages/hourly_wages.csv
```

```
--2026-03-24 07:05:15-- https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Hourly_wages/hourly_wages.csv
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.133, 185.199.110.133, 185.199.111.133
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 13436 (13K) [text/plain]
Saving to: 'hourly_wages.csv.5'
```

```
hourly_wages.csv.5 100%[=====] 13.12K --.-KB/s in 0.001s
```

```
2026-03-24 07:05:15 (23.5 MB/s) - 'hourly_wages.csv.5' saved [13436/13436]
```

- ✓ b-) Ler o dataset "*Hourly_wages/hourly_wages.csv*" como dataframe utilizando a biblioteca Pandas e mostrar as 5 primeiras e as 5 últimas linhas do dataset.

```
#importando dependências necessárias
import pandas as pd
import statistics
import math
import numpy as np
from scipy import stats

#lendo e criando um dataset atribuido ao objeto hourly_wages
hourly_wages = pd.read_csv("hourly_wages.csv")
```

Clique duas vezes (ou pressione "Enter") para editar

- ✓ c-) Obter um resumo da estatística descritiva dos dados utilizando um único comando (função).

```
hourly_wages.describe()
```

	wage_per_hour	union	education_yrs	experience_yrs	age	female	marr	south	manufactu
count	534.000000	534.000000	534.000000	534.000000	534.000000	534.000000	534.000000	534.000000	534.000000
mean	9.024064	0.179775	13.018727	17.822097	36.833333	0.458801	0.655431	0.292135	0.151163
std	5.139097	0.384360	2.615373	12.379710	11.726573	0.498767	0.475673	0.455170	0.338541
min	1.000000	0.000000	2.000000	0.000000	18.000000	0.000000	0.000000	0.000000	0.000000
25%	5.250000	0.000000	12.000000	8.000000	28.000000	0.000000	0.000000	0.000000	0.000000
50%	7.780000	0.000000	12.000000	15.000000	35.000000	0.000000	1.000000	0.000000	0.000000
75%	11.250000	0.000000	15.000000	26.000000	44.000000	1.000000	1.000000	1.000000	0.000000
max	44.500000	1.000000	18.000000	55.000000	64.000000	1.000000	1.000000	1.000000	1.000000

#apesar de nao exigido, metodos adequados da pandas para um melhor panorama dos dados seriam

```
hourly_wages.info()
hourly_wages.tail()
hourly_wages.head()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 534 entries, 0 to 533
Data columns (total 10 columns):
#   Column              Non-Null Count  Dtype
---  ---
0   wage_per_hour       534 non-null   float64
1   union               534 non-null   int64
2   education_yrs       534 non-null   int64
3   experience_yrs      534 non-null   int64
4   age                 534 non-null   int64
5   female              534 non-null   int64
6   marr                534 non-null   int64
7   south               534 non-null   int64
8   manufacturing        534 non-null   int64
9   construction        534 non-null   int64
dtypes: float64(1), int64(9)
memory usage: 41.8 KB
```

	wage_per_hour	union	education_yrs	experience_yrs	age	female	marr	south	manufacturing	construction
0	5.10	0	8	21	35	1	1	0	1	0
1	4.95	0	9	42	57	1	1	0	1	0
2	6.67	0	12	1	19	0	0	0	1	0
3	4.00	0	12	4	22	0	0	0	0	0
4	7.50	0	12	17	35	0	1	0	0	0

Próximas etapas:

[Gerar código com hourly_wages](#)
[New interactive sheet](#)

- ✓ d-) Calcule a proporção de funcionários de sexo masculino e feminino.

```
total_mulheres = hourly_wages[hourly_wages['female'] == 1].shape[0]

total_homens = hourly_wages[hourly_wages['female'] == 0].shape[0]

prop_feminino = (total_homens)/(total_mulheres + total_homens)
prop_masculino = 1 - prop_feminino

print("PROPORÇÃO DE GÊNERO")
print("Feminino = ", prop_feminino)
print("Masculino = ", prop_masculino)
```

```
PROPORÇÃO DE GÊNERO
Feminino = 0.5411985018726592
Masculino = 0.45880149812734083
```

- ✓ e-) Calcule a proporção de casados e solteiros.

```
total_casados = hourly_wages[hourly_wages['union'] == 1].shape[0]
total_solteiros = hourly_wages[hourly_wages['union'] == 0].shape[0]
```

```
proporcao_casados = total_casados/(total_solteiros + total_casados)
proporcao_solteiros = total_solteiros/(total_solteiros + total_casados)

print("PROPORÇÃO MATRIMONIAL")
print("Casados = ", proporcao_casados)
print("Solteiros = ", proporcao_solteiros)
```

```
PROPORÇÃO MATRIMONIAL
Casados = 0.1797752808988764
Solteiros = 0.8202247191011236
```

- ✓ f-) Calcule as médias de cada uma das variáveis: anos de educação, anos de experiência e idade

```
media_educacao = hourly_wages['education_yrs'].mean()
media_experiencia = hourly_wages['experience_yrs'].mean()
media_idade = hourly_wages['age'].mean()

print("TAXAS MÉDIAS")
print("Educação = ", media_educacao)
print("Experiência = ", media_experiencia)
print("Idade = ", media_idade)
```

```
TAXAS MÉDIAS
Educação = 13.0187265917603
Experiência = 17.822097378277153
Idade = 36.833333333333336
```

- ✓ g-) Calcule as medianas de cada uma das variáveis: anos de educação, anos de experiência e idade.

```
mediana_educacao = hourly_wages['education_yrs'].median()
mediana_exp = hourly_wages['experience_yrs'].median()
mediana_age = hourly_wages['age'].median()

print("MEDIANAS ABSOLUTAS")
print(f"Educação = {mediana_educacao}")
print(f"Experiência = {mediana_exp}")
print(f"Idade = {mediana_age}")
```

```
MEDIANAS ABSOLUTAS
Educação = 12.0
Experiência = 15.0
Idade = 35.0
```

- ✓ h-) Calcule as modas de cada uma das variáveis: anos de educação, anos de experiência e idade.

```
moda_educacao = hourly_wages['education_yrs'].mode()
moda_exp = hourly_wages['experience_yrs'].mode()
moda_idade = hourly_wages['age'].mode()

print("MEDIANAS ABSOLUTAS")
print(f"Educação = {moda_educacao}")
print(f"Experiência = {moda_exp}")
print(f"Idade = {moda_idade}")
```

```
MEDIANAS ABSOLUTAS
Educação = 0 12
Name: education_yrs, dtype: int64
Experiência = 0 14
Name: experience_yrs, dtype: int64
Idade = 0 32
Name: age, dtype: int64
```

- ✓ i-) Analisando especificamente a variável **idade**, responda: qual é a idade do conjunto de dados em que **70%** dos funcionários apresentam idade inferior?

```
idade_70 = hourly_wages['age'].quantile(0.70)

print(f"Idade em que 70% dos funcionários são mais novos (Percentil 70): {idade_70} anos")
```

```
Idade em que 70% dos funcionários são mais novos (Percentil 70): 42.0 anos
```

- ✓ j-) Analisando especificamente a variável **anos de experiência**, responda: qual é a quantidade de anos de experiência no conjunto de dados em que 10% dos funcionários ainda não possuem?

```
exp_10 = hourly_wages['experience_yrs'].quantile(0.10)

print(f"Quantidade de anos de experiência que 10% dos funcionários ainda não possuem: {exp_10} anos")
```

Quantidade de anos de experiência que 10% dos funcionários ainda não possuem: 3.0 anos

- ✓ k-) Calcule o desvio-padrão de cada um dos atributos: anos de educação, anos de experiência e idade.

```
desvios = hourly_wages[['education_yrs', 'experience_yrs', 'age']].std()

print("Desvio Padrao Puro")
print(desvios)
print("-" * 30)

#comparacao c CV
medias = hourly_wages[['education_yrs', 'experience_yrs', 'age']].mean()
cv = (desvios / medias) * 100

print("Coeficiente Percentual de Variação (CV)")
print(cv)

#valida qual eh maior
maior_variabilidade = cv.idxmax()
print(f"\nJustificativa: O atributo com maior variabilidade é '{maior_variabilidade}' porque possui o maior Coefi")
print("Usamos o CV em vez do desvio-padrão direto porque as colunas possuem médias e escalas diferentes.")
```

```
Desvio Padrao Puro
education_yrs    2.615373
experience_yrs   12.379710
age             11.726573
dtype: float64
-----
Coeficiente Percentual de Variação (CV)
education_yrs    20.089312
experience_yrs   69.462700
age             31.836849
dtype: float64
```

Justificativa: O atributo com maior variabilidade é 'experience_yrs' porque possui o maior Coeficiente de Variação. Usamos o CV em vez do desvio-padrão direto porque as colunas possuem médias e escalas diferentes.

- ✓ l-) Determine qual dos três atributos apresenta maior variabilidade: anos de educação, anos de experiência ou idade? Justifique a sua resposta.

```
print(f"\nJustificativa: O atributo com maior variabilidade é '{maior_variabilidade}' porque possui o maior Coefi")
print("Usamos o CV em vez do desvio-padrão direto porque as colunas possuem médias e escalas diferentes.")
```

Justificativa: O atributo com maior variabilidade é 'experience_yrs' porque possui o maior Coeficiente de Variação. Usamos o CV em vez do desvio-padrão direto porque as colunas possuem médias e escalas diferentes.

- ✓ m-) Leia o conjunto de dados [Atlas_Brasil_2014.csv](https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Atlas/Atlas_Brasil_2014.csv)

```
import pandas as pd

#lendo o dataset do link raw (puro)
url_atlas = "https://raw.githubusercontent.com/malegopc/DSBD/main/Datasets/Atlas/Atlas_Brasil_2014.csv"
atlas_brasil = pd.read_csv(url_atlas)

#exibindo as primeiras linhas pra termos crtzta
display(atlas_brasil.head())
```

	ESTADO	MORT1	ANOSEST	T_ANALF25M	RDPC	POPT	IDHM	
0	RO	20.82	8.31	10.66	667.41	1641072	0.715	
1	AC	18.37	7.95	17.19	548.24	762502	0.719	
2	AM	19.38	9.21	8.06	579.45	3769444	0.709	
3	RR	17.57	9.29	9.95	665.19	472758	0.732	
4	PA	17.65	7.78	12.81	469.47	7615746	0.675	

- n-) Calcule a média do IDHM.

```
media_idhm = atlas_brasil['IDHM'].mean()

print(f"Media do IDHM é = {media_idhm:.4f}")
```

```
Media do IDHM é = 0.7376
```

o-) Qual é a taxa de mortalidade em que 50% dos estados apresentam taxa inferior?

```
mortalidade_50 = atlas_brasil['MORT1'].quantile(0.50)

print(f"A taxa de mortalidade em que 50% apresentam taxa inferior é: {mortalidade_50}")
```

```
A taxa de mortalidade em que 50% apresentam taxa inferior é: 16.86
```

p-) Calcule qual o valor de RDPC (renda per capita) em que 25% dos estados apresentam valor superior.

```
rdpc_25_sup = atlas_brasil['RDPC'].quantile(0.75)

print(f"O valor de RDPC em que 25% dos estados apresentam valor superior é: R$ {rdpc_25_sup:.2f}")
```

```
O valor de RDPC em que 25% dos estados apresentam valor superior é: R$ 885.16
```

q-) Determine dentre as duas variáveis: T_ANALF25M (Taxa de analfabetismo - 25 anos ou mais) ou RDPC (Renda per capita média), qual apresenta maior variabilidade. Justifique a sua resposta.

```
colunas_analise = ['T_ANALF25M', 'RDPC']

desvios_atlas = atlas_brasil[colunas_analise].std()
medias_atlas = atlas_brasil[colunas_analise].mean()

cv_atlas = (desvios_atlas / medias_atlas) * 100

print("--- Coeficiente de Variação (CV) em % ---")
print(cv_atlas)

maior_var_atlas = cv_atlas.idxmax()

print(f"\nJustificativa: A variável que apresenta maior variabilidade é '{maior_var_atlas}' porque possui o maior")
print("Utilizamos o Coeficiente de Variação (CV) para justificar a resposta, e não o desvio-padrão absoluto, porqu
```

```
--- Coeficiente de Variação (CV) em % ---
T_ANALF25M    59.004758
RDPC          37.275119
dtype: float64
```

```
Justificativa: A variável que apresenta maior variabilidade é 'T_ANALF25M' porque possui o maior Coeficiente de V
Utilizamos o Coeficiente de Variação (CV) para justificar a resposta, e não o desvio-padrão absoluto, porque as d
```